

数据挖掘课程项目开题报告

项目基本信息

- 课题：面向计算机科学论文的证据约束型 GraphRAG 问答系统
- 项目目标：构建“知识图谱检索 + 路径证据推理”的问答系统，在长文本问答场景下减少幻觉，并与传统向量检索 RAG 进行系统对比评测。

团队分工

成员	角色	主要职责
吴雨霏、王文正	数据与审计负责人	数据下载、清洗、质量审计、脏数据类型标注
唐易成	图谱构建负责人	实体/关系抽取、实体规范化、Neo4j 图存储
李昊	检索与生成负责人	向量RAG基线、GraphRAG检索器、答案生成与拒答策略
牛煜雯	评测负责人	指标实现、消融实验、分析与报告

4.1 问题定义（Problem Definition）

4.1.1 研究背景与动机

面向科研论文的问答通常需要跨段落、跨章节整合证据。传统向量RAG在“相似度检索 + 拼接上下文”范式下，容易在以下场景出现幻觉：

- 检索到语义相近但逻辑链条不完整的段落；
- 问题要求多跳推理（如“方法A为何优于方法B”）时，证据分散在实验设置、结果分析、附录等位置；
- 当问题不可回答时，模型倾向于“编造合理答案”而非拒答。

因此，本项目拟引入 GraphRAG：将论文中的实体（任务、模型、数据集、指标、结论等）及其关系结构化为知识图谱，以“子图检索 + 路径证据约束”替代纯相似度拼接，增强答案可追溯性并抑制幻觉。

4.1.2 任务形式化

给定论文语料库 $\mathcal{D}=\{d_i\}_{i=1}^N$ ，每篇论文由段落集合 $\mathcal{P}_i$ 构成。通过信息抽取构建知识图谱 $G=(V,E)$ ，其中 V 为实体节点， E 为关系边，且每条边/节点关联来源证据段落ID。对任意问题 q ，系统输出：

- 答案 a
- 证据集合 $S \subseteq \cup_i \mathcal{P}_i$
- 图推理路径 Π （由若干实体-关系链组成）
- 置信度 $c \in [0,1]$

优化目标：

1. 提高答案正确性（Answer F1 / EM）；
2. 提高证据一致性（Evidence F1）；
3. 降低幻觉率（Unsupported Claim Rate）；
4. 在不可回答问题上提升可靠拒答能力。

4.2 数据来源证明与初步探勘（Data Sourcing & Initial Audit）

4.2.1 数据来源

本项目选择 **QASPER**（计算机科学/NLP论文问答数据集）：

- Hugging Face 数据集链接：<https://huggingface.co/datasets/allenai/qasper>
- 论文：Dasigi et al., 2021, *A Dataset of Information-Seeking Questions and Answers Anchored in Research Papers*.

可直接使用：

- `datasets.load_dataset("allenai/qasper")`

4.2.2 数据规模与特征

- 总体规模：约 **1,585** 篇论文、**5,049** 个问题。
- 官方划分（示例）：Train 888篇 / Validation 281篇 / Test 416篇。
- 字段包含：标题、摘要、全文分节段落、问题、答案、多标注证据（包括段落及部分图表证据）。

4.2.3 数据初步挑战

本数据集主要挑战如下：

1. **长文档与结构噪声**：论文全文由自动抽取流程生成，段落切分、章节层次、公式/表格文本化会带来噪声。
2. **证据分散与多跳推理**：不少问题需要多段证据联合才能回答（跨章节、跨段落）。
3. **异构答案类型**：包含抽取式、自由文本、是/否及不可回答问题，评测与生成策略复杂。
4. **术语别名与实体歧义**：同一模型/任务有缩写、别名或上下文依赖含义，实体规范化难度高。

4.3 初步方法与技术栈（Preliminary Methodology）

4.3.1 基线模型（Baseline）

为保证结论可信，设置以下基线：

1. **BM25-RAG**：关键词检索 + LLM生成。
2. **Dense Vector RAG**：段落向量检索（FAISS） + LLM生成。

4.3.2 核心方案：证据约束 GraphRAG

核心流程：

1. **图谱构建**：从论文段落抽取实体与关系（如 *Method-uses-Dataset*、*Method-achieves-Metric*、*Paper-claims-Conclusion*），并保留来源段落ID。
2. **实体规范化**：对模型名/数据集名/指标名做别名归一，减少图中重复节点。
3. **问题图化**：将问题解析为目标实体与关系约束，执行子图检索（k-hop、路径评分）。
4. **路径证据拼接**：按图路径组织证据上下文，要求生成答案时给出证据引用。

5. **拒答机制**：当路径证据不足或冲突时输出“证据不足”，降低强行作答幻觉。

4.3.3 计划技术栈

- 语言与框架：Python, PyTorch, Hugging Face Datasets
- 检索与RAG：FAISS / BM25, LangChain 或 LlamaIndex
- 图数据库：Neo4j
- 信息抽取与文本处理：spaCy/scispaCy + LLM辅助抽取
- 评测：RAGAS (faithfulness)、自定义证据命中脚本、NLI一致性检测

4.4 实验设计与评估指标 (Experiment Design & Metrics)

4.4.1 评估指标

1. **答案质量**：Exact Match、Token F1。
2. **证据质量**：Evidence Precision / Recall / F1（与标注证据段落对比）。
3. **幻觉控制**：
 - Faithfulness (RAGAS) ；
 - Unsupported Claim Rate（答案句子是否被证据支持）。
4. **可用性指标**：不可回答问题上的拒答准确率、平均响应时延。

4.4.2 对照与消融设计

主对照：

- C1: Vector RAG（传统基线）
- C2: GraphRAG（完整方案）

关键消融（证明核心模块有效）：

- A1: GraphRAG 去掉关系边（仅实体节点检索）；
 - A2: GraphRAG 关闭拒答机制。
-

4.5 风险清单与排期 (Risk Assessment & Timeline)

4.5.1 风险清单与预案

****风险1：**图谱抽取质量不足，导致检索路径错误。****预案：**

- 先定义小而稳的关系模式（任务-方法-数据集-指标）再逐步扩展；
- 进行小样本人审，迭代抽取规则；
- 保留向量检索回退通道，避免“图谱失败即系统不可用”。

****风险2：**模型调用成本或算力受限。****预案：**

- 优先使用开源小模型（如 7B 级）+ 批处理离线构图；
- 高成本环节（如复杂抽取）采用缓存与增量更新；
- 必要时切换 API + 严格采样评测，保证实验可完成。

4.5.2 里程碑排期

- 第8周（开题）：**确定任务边界、完成数据审计、实现可运行的 Vector RAG 基线。
- 第9周：**完成图谱schema设计、实体关系抽取、Neo4j 入库与可视化检查。
- 第10周：**完成 GraphRAG 初版与主对照实验（C1/C2）。
- 第11周：**完成消融实验（A1/A2）、分析汇总。

AI 辅助工具使用声明

本项目使用 AI 工具（ChatGPT/Cursor）辅助：

- 开题报告初稿组织；
- 技术路线梳理与实验设计检查。