课程项目开题要求

1. 总体目标

课程项目要求学生组成 **3-5 人团队**，围绕真实场景、复杂分布及具有一定挑战性的数据挖掘问题，完成端到端的数据分析、模型构建与实验评估。

- **不鼓励**（拒绝）仅仅使用干净的经典数据集（如 Titanic、Iris 等）并调用现成机器学习包进行简单分类或回归预测的"玩具项目"。
- 更看重项目在**数据质量审计、因果推断、图结构挖掘、大语言模型辅助（Agent/RAG）**或**复杂现实业务场景（如过程挖掘）**等高级维度的探索和实现。

2. 核心要求与时间线

- **团队规模**：3-5 人/组，明确各成员的分工（如数据处理、模型开发、实验评测等）。3 人组在工作量期望上略低于 5 人组（代码模块数、对比实验数量等），评审时将综合考量。
- **提交截止时间**：**第 8 周**。
- **开题分值**：本次开题报告占期末项目总分（40%）中的 **10%**，中期汇报占 10%，最终答辩占 20%。
- **修改截止时间**：若开题被判为需要修改，需在反馈发出后 **7 天内**重新提交，逾期视为未提交。
- **提交物**：
  1. 一份格式规范的 **PDF 开题报告**（页数建议在 3-5 页以内，重点突出）。
  2. 一个初始化的 **GitHub 仓库链接**（仓库至少包含基础的 `README.md`、`.gitignore`，且已设为公开）。

---

3. 建议选题方向（包括但不限于以下方向）

如果还没有明确的方向，可以参考以下建议，选择一个你们感兴趣的领域深入探索：

1. **复杂 Data-Centric 改进**：选取医学/风控等高噪数据集，系统实施 OOD（out-of-distribution）泛化增强、标签去噪与弱监督填补，量化证明纯数据层面改进带来的显著增益。
2. **企业级过程发现（Process Mining）**：利用真实开源 ERP/OA 日志数据，挖掘隐蔽的业务瓶

颈、绘制过程拓扑，并使用反事实推理提出具体优化建议。

3. **因果增量策略优化（Uplift Modeling）**：使用真实电商、金融观测数据训练 Uplift Model，与传统 CTR 模型进行对比，并证明其在营销 ROI 上的显著改进。
4. **GraphRAG 领域问答系统**：构建基于专业文献（医学/法律/计算机科学）的知识图谱，通过 GraphRAG 对抗长文本推理时的幻觉问题，并与传统的、基于向量检索的 RAG 系统进行详实的消融与对比评测。
5. **Agentic 数据科学家评估平台**：开发或二次开发基于大语言模型的 Data Agent 框架，使用多个完全未知的"脏数据集"作为测试床，系统评估 Agent 在自动完成数据清洗、特征工程、防止数据泄漏等任务上的成功率与漏洞缺陷。

---

4. 开题报告必须包含的内容

请在开题报告中明确涵盖以下 5 个部分：

4.1. 问题定义（Problem Definition）

- **研究背景与动机**：要解决什么具体问题？为什么这个问题值得解决？它在现实世界中的业务或科学价值是什么？
- **任务形式化**：用清晰的数学或逻辑语言，定义输入是什么，输出是什么？（例如：输入是包含隐式反馈的用户行为序列，输出是干预后的增量转化概率）。

4.2. 数据来源证明与初步探勘（Data Sourcing & Initial Audit）

- **数据来源**：数据从哪里获取？（Kaggle、企业合作、开源机构、或自行爬取）。请附上数据获取链接或声明。**注意：开题时数据必须已经可以访问和下载。**
- **数据规模与特征**：数据量级多大？特征维度多少？
- **数据初步挑战（关键点）**：提前识别数据的痛点，例如缺失值比例过高、存在类别严重不平衡、可能存在概念漂移（Concept Drift）等。

4.3. 初步方法与技术栈（Preliminary Methodology）

- **基线模型：打算用什么相对简单/经典的方法作为基线进行对比？
- **核心算法/技术方案**：准备尝试的进阶方案或核心创新点是什么？（如引入弱监督标签、图神经网络、因果推断框架等）。
- **技术栈**：计划使用的主要工具和库（如 PyTorch, Snorkel, pm4py, LangChain/LlamaIndex 等）。

4.4. 实验设计与评估指标（Experiment Design & Metrics）

- **评估指标（Metrics）**：如何衡量成功？（不要只写 Accuracy，请根据业务场景考虑 AUC, F1, Uplift Score, 业务成本等）。
- **消融/对照实验设计思路**：如何证明核心改动/进阶方法是有效的？（例如：将设计包含/不包含某模块的对比测试，或者传统 RAG 与 GraphRAG 的效果对比）。

4.5. 风险清单与排期（Risk Assessment & Timeline）

- **项目风险清单（Risk List）**：请列出 1-2 个可能导致项目失败或严重受阻的风险点，并给出预案。例如："如果计算资源不足以微调 7B 模型，我们将改为使用 API 调用结合 Prompt Engineering"。
- **里程碑排期**：结合课程进度安排（第 12 周提交中期检查报告，第 16 周进行答辩），给出组内成员分工与大致的时间节点计划。

---

5. 审核标准与反馈（Review Criteria）

将根据以下标准对各组开题进行审核：

- 通过**：问题定义清晰，数据真实且具有一定挑战性，实验设计包含对照组思路，具备可落地和评测的指标。
- **需修改**：问题太大/太小，或仅调用现成包缺乏深度，或数据来源不明确。需根据反馈调整范围。
- **打回重写**：纯"玩具项目"，套用公开代码不作任何思考，或完全没有技术挑战性。

6. AI 辅助工具使用规范

本项目**允许**使用 ChatGPT、Copilot 等 AI 工具辅助代码编写、文献检索和报告撰写，但须遵守以下规范：

- 开题报告中须声明团队使用了哪些 AI 工具（如未使用则注明"未使用"）。
- AI 工具输出的内容必须经过团队成员理解、审查和修改，不得原文照搬。
- 核心算法设计、实验设计与分析结论必须是团队独立完成的工作，不得完全依赖 AI 生成。

> **提示**：如果项目偏向工程实践（如 Agent 搭建），请重点阐述评测体系；如果偏向算法研究，请重点阐述数据的独特性和消融实验设计。