

数据挖掘课程项目 - 中期进展报告

项目当前阶段：中期 GraphRAG 原型已跑通，并完成真实 QASPER 数据验证。当前结果显示检索召回和答案 F1 有提升，但延迟与拒答策略仍需优化。

0. 项目基本信息

- 项目名称：面向计算机科学论文的证据约束型 GraphRAG 问答系统
- 项目链接：https://github.com/RouVen-crp/DataExcavate_Proj
- 小组成员与分工：

姓名	学号	组内角色	开题以来的核心贡献	中期之后的分工规划
吴雨霏	3220251395	数据与审计	数据获取、清洗规则确认、数据质量审计	扩大数据审计范围，补充问题子集分析
王文正	3120250953	数据与审计	预处理验收、审计指标核对、运行结果整理	复核实验日志，整理报告图表
唐易成	3220251363	图谱构建	完成中期轻量图检索原型	优化实体、关系和边权设计
李昊	3220251322	检索与生成	完成基线检索、GraphRAG 检索与拒答策略	补充对照实验，优化回答质量
牛煜雯	3220251288	评测	完成核心指标和失败案例输出	负责消融实验和最终实验分析

1. 项目概述与当前状态

1.1. 中期里程碑达成情况

- 开题计划目标：构建面向论文问答的 GraphRAG 系统，通过检索证据和拒答机制降低无依据回答风险，并与常规 RAG 基线进行对比。
- 中期实际达成：已完成 CPU-only、可一键复现的中期原型，覆盖数据处理、数据审计、基线检索、GraphRAG 检索、抽取式回答、拒答和评测。系统已在小切片和 train split 全量数据上完成验证。

1.2. 代码仓库状态审计

- 提交统计：
 - main 分支总 commit 数：28 次。
 - 开题后新增 commit 数：28 次。
 - 活跃贡献人数：5/5人均有提交。
- 分支与协作方式：

- 当前主分支: `main`。
- 远程仓库: `origin https://github.com/RouVen-crp/DataExcavate_Proj.git`。
- Git 历史中可见 PR 合并记录, 例如 `Merge pull request #9 from yezhuqiull11/main`、`Merge pull request #10 from HUAIJURENSHEN/main` 和 `Merge pull request #11 from codex/full-gasper-validation`。

- 当前仓库目录结构:

```

.
├── AGENTS.md                # agent 工作约定
├── CONTEXT.md              # 项目领域词汇表
├── README.md               # 环境配置、一键运行命令、输出文件说明
├── __pycache__
│   └── run_midterm.cpython-314.pyc
├── docs
│   ├── COLLABORATOR_HANDOFF.md
│   ├── PROJECT_HANDOFF.md
│   ├── adr
│   ├── agent_handoff.md
│   ├── agents
│   ├── image
│   ├── 小组项目开题.pdf
│   ├── 小组项目选题和指南.pdf
│   ├── 项目中期进展报告.md
│   └── 项目中期进展报告模板.md
├── requirements.txt         # Python 测试依赖: pytest
├── run_midterm.py           # 一键运行入口, 串联数据、检索、回答、评测与导出
├── run_scale_experiments.py # 分层规模实验入口
├── src/
│   ├── __init__.py
│   ├── __pycache__
│   ├── answering.py        # Evidence-Constrained Extractive Answer 与拒答
│   ├── audit.py            # 数据审计: 长度、evidence 映射、unanswerable 统计
│   ├── data_loader.py      # 本地 JSON/JSONL 与官方 QASPER v0.3 下载缓存
│   └── evaluate.py         # Evidence Recall@K、Answer Token F1、Refusal Accuracy、失
败案例
│   ├── graph_rag.py        # Rule-Based Co-Occurrence GraphRAG、trace 输出
│   ├── preprocess.py       # QASPER 标准化、evidence 映射、Processed QASPER Slice 写出
│   └── retrieval.py        # TF-IDF RAG Baseline
├── tests/                  # pytest 行为测试与 smoke suite
│   ├── __pycache__
│   ├── run_smoke_tests.py
│   ├── test_audit.py
│   ├── test_data_loader.py
│   ├── test_graph_rag.py
│   ├── test_preprocess.py
│   ├── test_refusal_failures.py
│   ├── test_runner_smoke.py
│   └── test_tfidf_baseline.py

```

9 directories, 30 files

2. 数据工程与审计落地

2.1. 原始数据审计反馈

开题报告确定数据集为 QASPER。中期阶段先审计 train split 小切片：12 篇论文、60 个 QA、1053 个段落；后续又补充 train split 全量验证。运行输出见 `results/qasper_midterm/audit.json`。

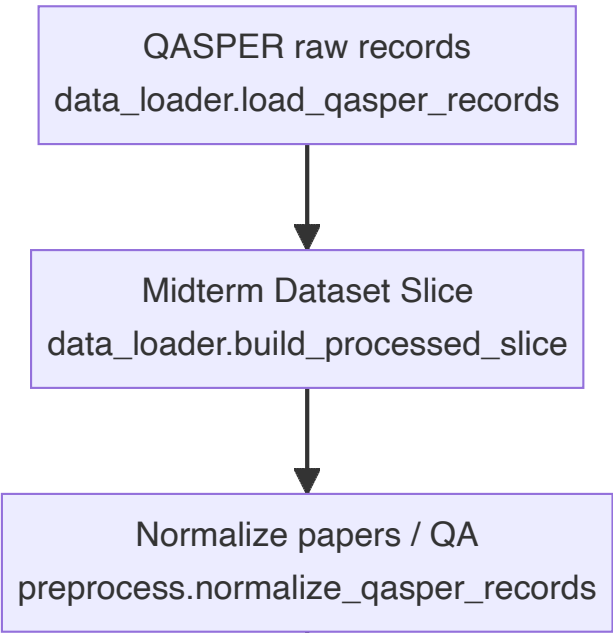
已验证的数据问题

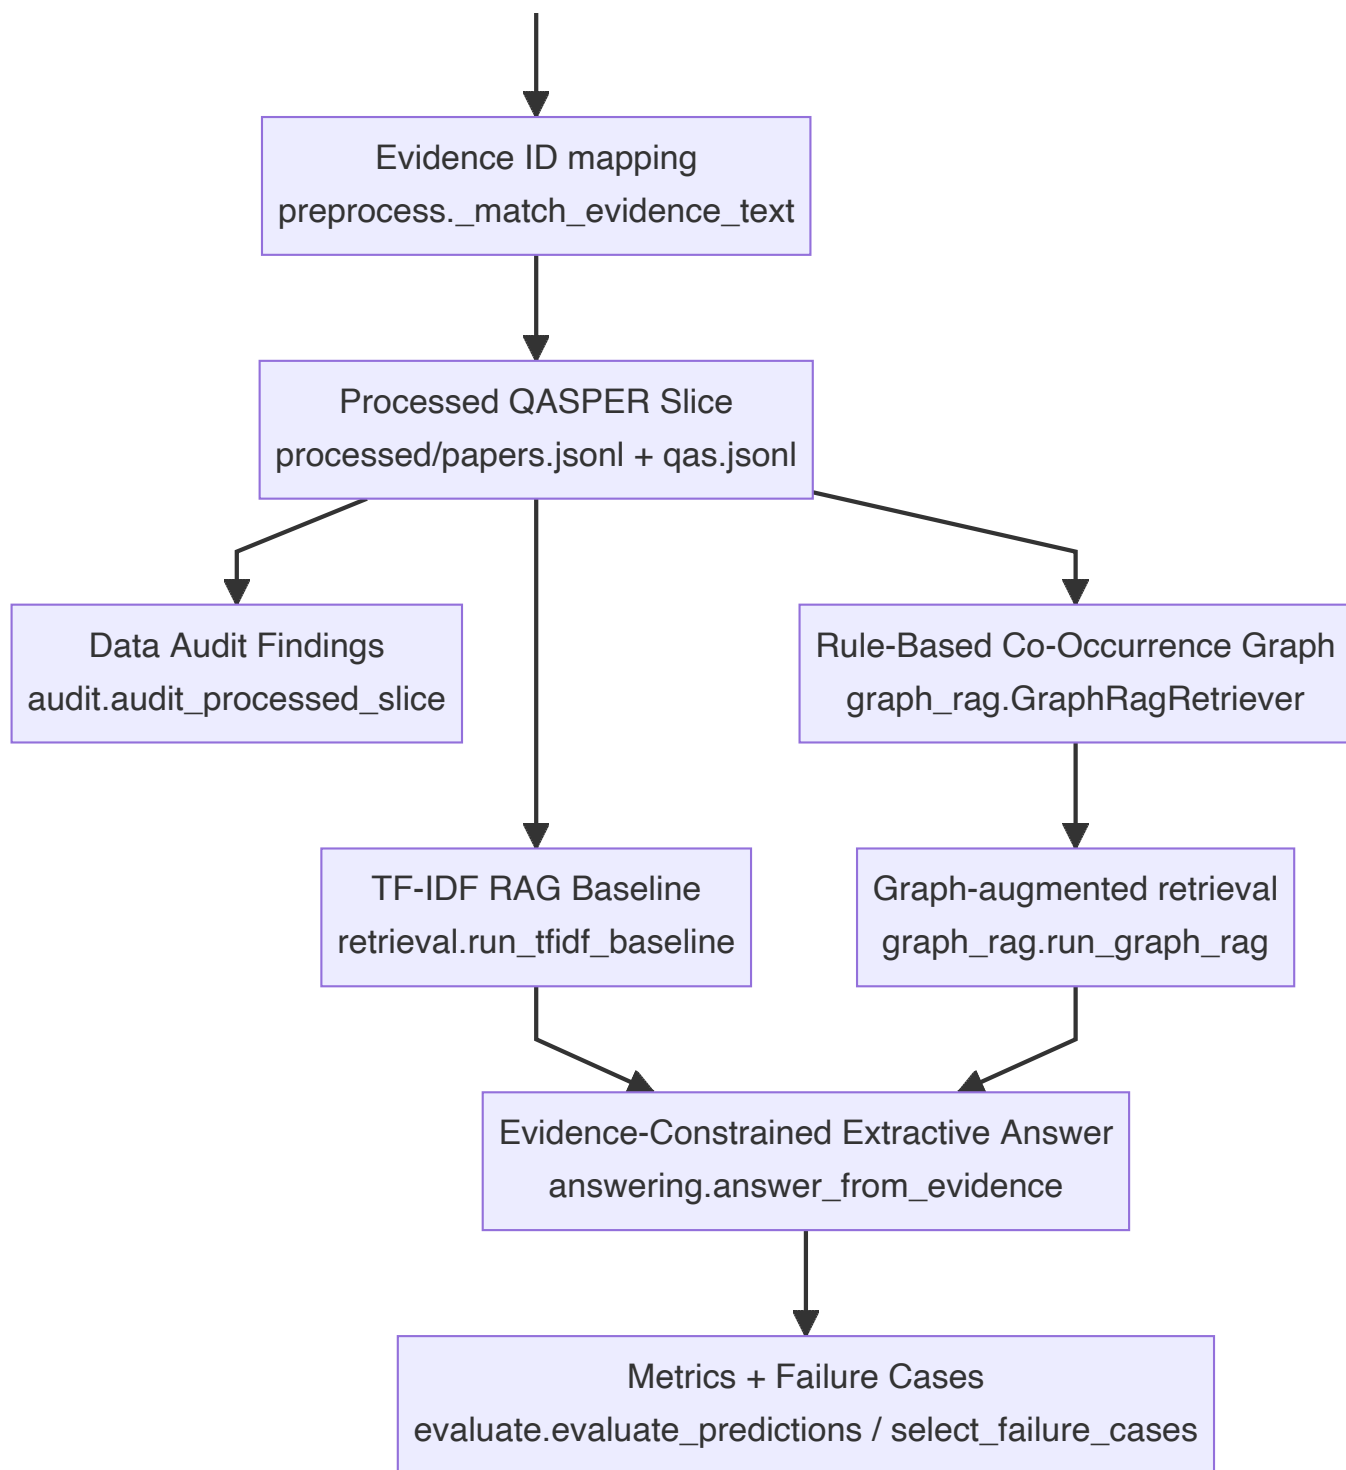
数据问题	量化规模	当前处理	中期结论
文档长度差异大	12 篇中 5 篇超过 4000 words	段落级检索，见 <code>src/retrieval.py</code>	降低整篇论文直接检索的噪声
长段落影响答案抽取	1053 段中 11 段超过 250 words	从证据段中抽取相关句子，见 <code>src/answering.py</code>	回答上下文更可控
部分 evidence 难以映射	60 个 QA 中 7 个存在缺失或不完整	增加 evidence 匹配与审计记录，见 <code>src/preprocess.py</code> 、 <code>src/audit.py</code>	避免把数据问题误判为模型失败
存在不可回答问题	小切片 18.33%，train split 全量 10.72%	增加拒答输出与指标统计，见 <code>src/answering.py</code> 、 <code>src/evaluate.py</code>	拒答能力已可度量，但仍需调优

需继续观察的问题

问题	中期观察	后续处理
evidence 部分匹配	小切片中未明显出现大量 partial mismatch	扩大数据后继续观察
术语别名与实体歧义	中期版仅做轻量词项抽取	终期继续优化实体规范化

2.2. 数据流与预处理管道





3. 基线模型与核心算法实现

3.1. 基线模型运行情况说明

- **开题计划基线：**BM25-RAG（关键词检索 + LLM 生成）和 Dense Vector RAG（段落向量检索 / FAISS + LLM 生成）。
- **中期已实现基线：**TF-IDF RAG Baseline。系统按论文段落检索 top-k 证据，并基于证据抽取回答；BM25 或 Dense Vector RAG 将作为终期增强对照。
- **运行环境：**Windows + Python 3.11 Conda 环境，CPU-only；不依赖外部服务。
- **一键复现命令：**

```
python run_midterm.py --max-papers 20 --max-qas 60 --top-k 5 --output-dir
results/qasper_midterm
```

- 全量验证命令：

```
python run_midterm.py --max-papers all --max-qas all --top-k 5 --output-dir
results/qasper_train_full
```

- 分层对比实验命令：

```
python run_scale_experiments.py --scale 20:60 --scale 100:300 --scale all:all --top-k 5 --
output-dir results/scale_experiments
```

分层实验会保存各规模结果，并生成汇总文件 `results/scale_experiments/comparison.json`。

- 关键输出日志片段：

```
papers=12 gas=60 output_dir=results\qasper_midterm
baseline_recall@5=0.420 baseline_f1=0.067
graphrag_recall@5=0.460 graphrag_f1=0.083
failure_cases=2
```

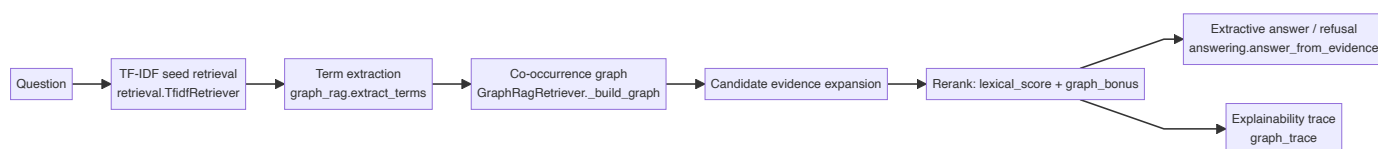
- 测试验证：

```
D:\miniconda3\envs\dm\python.exe -m pytest
12 passed

D:\miniconda3\envs\dm\python.exe tests\run_smoke_tests.py
smoke tests passed
```

3.2. 核心进阶算法开发进度

中期阶段实现了轻量版 GraphRAG：先用基线检索获取候选证据，再基于共现图扩展相关段落并重排。该版本重点验证“图增强检索是否带来收益”，完整实体规范化和更复杂的路径推理留到终期推进。



模块	对应文件	状态	备注
数据预处理	src/preprocess.py 、 src/data_loader.py	完成	支持 QASPER 数据读取和 evidence 映射
基线检索	src/retrieval.py	完成	TF-IDF 段落检索
GraphRAG 原型	src/graph_rag.py	完成中期版	轻量图扩展与重排
回答与拒答	src/answering.py	完成中期版	抽取式回答和拒答
评测框架	src/evaluate.py	完成	召回、F1、拒答和延迟指标
测试	tests/	完成	12 个 pytest 用例和 smoke tests

4. 中期实验结果与阶段性分析

4.1. 评估指标与测试集构建

- **评测数据集规模**：主表使用 QASPER train split 小切片：12 篇论文、60 个 QA、1053 个段落；另补充分层实验和 train split 全量验证。
- **中期已落地指标**：Evidence Recall@5、Answer Token F1、Refusal Accuracy、Average Latency。
- **暂未落地指标**：Exact Match、Evidence Precision/F1、Faithfulness、Unsupported Claim Rate 等，计划在终期继续补充。

4.2. 定量对比实验结果

模型方法	Evidence Recall@5	Answer Token F1	Refusal Accuracy	平均耗时
TF-IDF RAG Baseline	42.00%	0.067	18.18%	0.42 ms/query
GraphRAG 中期版	46.00% (+4.00%)	0.083 (+0.016)	18.18%	24.87 ms/query

结果说明：在 60 QA 快速复现切片中，GraphRAG 中期版的召回率和答案 F1 有提升，拒答准确率持平，但耗时更高。

4.3. 扩大规模与全量验证

小切片结果主要用于快速复现。为避免只根据小样本判断算法效果，项目已补充分层实验和 train split 全量验证。

数据规模	TF-IDF Recall@5	GraphRAG Recall@5	TF-IDF F1	GraphRAG F1	TF-IDF Latency	GraphRAG Latency
12 篇 / 60 QA	42.00%	46.00%	0.0671	0.0829	0.42 ms	24.87 ms
73 篇 / 300 QA	54.40%	54.40%	0.0897	0.0947	0.65 ms	84.28 ms
888 篇 / 2593 QA	51.07%	54.55%	0.0812	0.0909	3.95 ms	530.02 ms

全量结果表明，GraphRAG 在 Recall@5 和 Answer Token F1 上整体优于 TF-IDF baseline，但平均延迟明显上升，拒答准确率仍需单独优化。

4.4. 实验结果初步诊断与分析

#	Query 片段	模型输出	正确答案要点	失败原因	改进方向
1	What are the results?	INSUFFICIENT_EVIDENCE	多个模型的实验结果	结果类段落未被召回	提高结果、数值和表格相关证据权重
2	What are labels available in dataset for supervision?	INSUFFICIENT_EVIDENCE	negative、positive	数据集标签信息未被召回	加强 dataset/label 相关短语识别

- 总体优缺点小结：当前中期原型已能在真实数据上复现完整流程。GraphRAG 相比 TF-IDF 有小幅提升，但延迟和拒答质量仍是主要短板。终期阶段将重点优化检索扩展、对照基线和拒答策略。

5. 后续风险评估与冲刺排期

5.1. 风险清单动态调整

风险	当前状态	后续预案
图谱抽取质量不足	部分发生；中期版仍是轻量图检索	优化实体规范化、边权和检索回退
算力或外部服务受限	已规避；中期版可 CPU-only 运行	终期新增能力保持 optional 和可缓存
GraphRAG 延迟较高	已发生；全量实验中延迟明显高于基线	限制扩展范围，优化索引和重排流程
evidence 映射不完整	部分发生；少量样本影响评测	继续完善匹配策略，并在报告中单独标注

5.2. 终期冲刺详细排期（第 13 周 - 第 16 周）

周次	核心任务	责任人	交付物
第 13 周	完成中期提交与结果复核	吴雨霏、王文正、牛煜雯；全员复核	中期报告、运行日志、指标表
第 14 周	补充 BM25 或 Dense RAG 对照，优化检索扩展	李昊、唐易成	对照实验结果、优化版检索模块
第 15 周	完成主对照和消融实验	牛煜雯、李昊、唐易成	消融实验表、失败案例分析
第 16 周	整理最终交付与答辩材料	全员	最终报告、答辩 PPT、Demo 材料

6. AI 工具辅助使用记录

使用场景	AI 工具名称	具体辅助环节	团队审查与纠错说明
代码修改	Codex	辅助实现数据处理、检索、回答和评测模块	使用本地测试和真实数据运行验证
开题阶段材料组织	ChatGPT / Cursor	辅助梳理报告初稿和技术路线	团队成员人工审查与修改
中期报告检查	Codex	对照模板检查报告完整性和表达	团队成员定夺修改项并复核

中期自查清单 (Self-Check List) (提交前逐项确认)：

代码仓库

- ✓ GitHub 仓库已设为公开，且近两周内有真实的 commit 记录？
- ✓ 仓库 README.md 包含环境配置说明和一键复现命令，他人可独立运行？
- ✓ 所有组员至少有 1 次 commit？

数据与实验

- ✓ 数据审计表已填写，每条问题都给出了量化规模（百分比/数量）？
- ✓ 基线模型已完整跑通，报告中有实际的终端输出或截图为证？
- ✓ 进阶模型与基线已进行定量对比（有数字，不只是文字描述）？
- ✓ 误差分析部分包含至少 2 个具体的失败案例？

报告完整性

- ✓ 所有成员的分工和开题后的具体贡献都明确写入了成员分工表？
- ✓ 后续冲刺排期精确到周，责任人明确，且与当前进度匹配？
- ✓ AI 工具使用情况已如实填写（未使用也须注明）？

附录：

GitHub Insights 截图

RouVen-crp

DataExcavate_Proj

Code

Issues

Pull requests

Agents

Actions

Projects

Wiki

Security and quality

Insights

Settings

Q

Type [Z] to search

Pulse

Contributors

Community

Community standards

Traffic

Commits

Code frequency

Dependency graph

Network

Forks

Actions usage metrics

Actions performance metrics

May 25, 2026 – June 1, 2026

Period: 1 week

Overview

3 Active pull requests

8 Active issues

1- 3 Merged pull requests

1- 0 Open pull requests

8 Closed issues

0 New issues

Summary

Excluding merges, 5 authors have pushed 25 commits to main and 26 commits to all branches.

On main, 0 files have changed and there have been 0 additions and 0 deletions

Top Committers

1- 3 pull requests merged by 3 people

1- Add full QASPER validation workflow
#11 merged 35 minutes ago

1- Add explainable GraphRAG trace outputs
#10 merged yesterday

1- fix: 修复 HuggingFace QASPER 列式 answers 解析, 恢复评测指标
#9 merged 2 days ago

8 issues closed by 1 person

Processed QASPER Slice smoke path
#1 closed 3 days ago

Minimal test suite for baseline confidence
#8 closed 3 days ago

One-command midterm runner and README
#7 closed 3 days ago

Retrieval-Based Refusal and Failure Cases
#6 closed 3 days ago

Rule-Based Co-Occurrence GraphRAG path
#5 closed 3 days ago

TF-IDF RAG Baseline end-to-end
#4 closed 3 days ago

Midterm Dataset Slice and Data Audit Findings
#3 closed 3 days ago

Processed QASPER Slice smoke path
#2 closed 3 days ago

© 2026 GitHub, Inc.

Terms

Privacy

Security

Status

Community

Docs

Contact

Manage cookies

Do not share my personal information

Pulse

Contributors

Community

Community standards

Traffic

Commits

Code frequency

Dependency graph

Network

Forks

Actions usage metrics

Actions performance metrics

Contributors

Period: Last 3 months

Contributions: Commits

Contributions per week to main, excluding merge commits

Commits over time

Weekly from 2026年2月28日 to 2026年5月31日

Contributions

25 May

1 Jun

Mar '26

Apr '26

May '26

RouVen-crp

15 commits 3,049 ++ 130 --

#1

Contributions

Mar '26

Apr '26

May '26

Jun '26

evergreenee

7 commits 494 ++ 57 --

#2

Contributions

Mar '26

Apr '26

May '26

Jun '26

HUAIJURENSHEN

1 commit 127 ++ 14 --

#3

Contributions

Mar '26

Apr '26

May '26

Jun '26

n1404361306

1 commit 320 ++ 49 --

#4

Contributions

Mar '26

Apr '26

May '26

Jun '26